

Aplicación de un modelo predictivo de consumo de combustible a partir de *machine learning* y *random forest* para una aerolínea comercial colombiana

| Fecha de recibido: 14 de junio 2023 | Fecha de aprobado: 17 de abril 2024 |

| Reception date: June 14, 2023 | Approval date: April 17, 2024 |

| Data de recebimento: 14 de junho de 2023 | Data de aprovação: 17 de abril de 2024 |

Pedro Fernando Melo Daza

<https://orcid.org/0000-0002-0734-9358>

pedromelodaza@cedoc.edu.co

Magíster en Ingeniería

Investigador – Centro de Educación Militar,

Escuela de Aviación del Ejército, Colombia

Rol del investigador: teórico y escritura

ESAVE - Grupo de Investigación en Aviación Militar

Master's Degree in Engineering

Researcher – Military Education Center,

Army Aviation School, Colombia

Researcher's role: theoretical and writing

ESAVE - Military Aviation Research Group

Mestrado em Engenharia

Pesquisador – Centro de Educação Militar,

Escola de Aviação do Exército, Colômbia

Papel do investigador: teórico e escritor

ESAVE - Grupo de Investigação da Aviação Militar

Juan Andrés Bermúdez Gómez

<https://orcid.org/0000-0002-4973-6874>

juanandresbernandezgomez@gmail.com

Ingeniero Aeronáutico

Investigador – Centro de Educación Militar,

Escuela de Aviación del Ejército, Colombia

Rol del investigador: teórico y escritura

ESAVE - Grupo de Investigación en Aviación Militar

Aeronautical Engineering Student

Researcher - Center for Military Education,

Army Aviation School, Colombia

Researcher's role: theoretical and writing

ESAVE - Military Aviation Research Group

Estudante de Engenharia Aeronáutica

Investigador - Centro de Educação Militar,

Escola de Aviação do Exército, Colômbia

Papel do investigador: teórico e escrito

ESAVE - Grupo de Investigação em Aviação Militar

Sara Valentina González Medina

<https://orcid.org/0000-0003-1810-9613>

valentinagonzalezmedina@cedoc.edu.co

Ingeniera Aeronáutica

Investigadora – Centro de Educación Militar,

Escuela de Aviación del Ejército, Colombia

Rol del investigador: teórico y escritura

ESAVE - Grupo de Investigación en Aviación Militar

Aeronautical Engineering Student

Researcher - Center for Military Education, Army Aviation

School, Colombia

Researcher's role: theoretical and writing

ESAVE - Military Aviation Research Group

Estudante de Engenharia Aeronáutica

Investigador - Centro de Educação Militar,

Escola de Aviação do Exército, Colômbia

Papel do investigador: teórico e escrito

ESAVE - Grupo de Investigação em Aviação Militar

Cristian Lozano Tafur

<https://orcid.org/0000-0002-6653-6188>

ctistianlozanotafur@cedoc.edu.co

Magíster en Materiales y Procesos

Investigador – Centro de Educación Militar,

Escuela de Aviación del Ejército, Colombia

Rol del investigador: teórico y escritura

ESAVE - Grupo de Investigación en Aviación Militar

Master's Degree in Materials and Processes

Researcher – Military Education Center,

Army Aviation School, Colombia

Researcher's role: theoretical and writing

ESAVE - Military Aviation Research Group

Mestrado em Materiais e Processos

Pesquisador – Centro de Educação Militar,

Escola de Aviação do Exército, Colômbia

Papel do investigador: teórico e escritor

ESAVE - Grupo de Investigação da Aviação Militar

Samuel Fuentes Rodríguez

<https://orcid.org/0000-0001-6630-980X>

samuelfuentesrodriguez@cedoc.edu.co

Ingeniero Aeronáutico

Investigador – Fundación Universitaria

Los Libertadores, Colombia

Rol del investigador: teórico y escritura

ESAVE - Grupo de Investigación en Aviación Militar

Aeronautical Engineering Student

Researcher - Center for Military Education,

Army Aviation School, Colombia

Researcher's role: theoretical and writing

ESAVE - Military Aviation Research Group

Estudante de Engenharia Aeronáutica

Investigador - Centro de Educação Militar,

Escola de Aviação do Exército, Colômbia

Papel do investigador: teórico e escrito

ESAVE - Grupo de Investigação em Aviação Militar

Cómo citar este artículo: Melo Daza, P. F., Bermúdez Gómez, J. A., Lozano Tafur, C., González Medina, S. V., y Fuentes Rodríguez, S. (2024). Aplicación de un modelo predictivo de consumo de combustible a partir de *machine learning* y *random forest* para una aerolínea comercial colombiana. *Ciencia y Poder Aéreo*, 19(2), 122-134. <https://doi.org/10.18667/cienciaypoderaereo.826>



Aplicación de un modelo predictivo de consumo de combustible a partir de *machine learning* y *random forest* para una aerolínea comercial colombiana

Application of a predictive fuel consumption model using machine learning and random forest for a Colombian commercial airline

Aplicação de um modelo preditivo de consumo de combustível usando *machine learning* e *random forest* para uma companhia aérea comercial colombiana

Resumen: En la industria aeronáutica, los costos de producción del hidrocarburo JET A-1 experimentan un incremento cercano al 5 % semanal a través de los años, lo cual ha repercutido en un alza de los gastos para los operadores aéreos. En esta investigación, se propone crear un modelo de predicción del consumo de combustible para vuelos regionales, con base en los datos recolectados de vuelos de una aerolínea colombiana durante el período 2018-2019. Para la creación del modelo predictivo, se utilizó la biblioteca Sci-Kit Learn del lenguaje de programación Python, y el enfoque del problema fue la perspectiva de ‘problema inverso’. Luego se procedió con la ingeniería de características para mejorar la calidad del conjunto de datos obtenido y permitir una mayor precisión en la predicción. Se implementó el modelo de predicción para las variables identificadas como dependientes e independientes y, finalmente, se evaluó su rendimiento utilizando las métricas de error absoluto promedio (MAE), error cuadrático medio (MSE) y raíz del error cuadrático medio (RMSE). Los resultados indican que el modelo es capaz de efectuar la predicción del consumo de combustible, con errores bajos en valores cuantitativos.

Palabras clave: aprendizaje automático; bosques aleatorios; ingeniería de características; inteligencia artificial; métricas de evaluación; pronóstico de combustible.

Abstract: In the aeronautical industry, JET A-1 hydrocarbon production costs experience an increase of approximately 5% weekly over the years, which has resulted in a rise in expenses for air operators. This research proposes to create a fuel consumption prediction model for regional flights, based on data collected from flights of a Colombian airline during the period 2018-2019. To create the predictive model, the Sci-Kit Learn library of the Python programming language was used, and the problem was approached from an ‘inverse problem’ perspective. Feature engineering was then carried out to improve the quality of the obtained data set and allow for greater prediction accuracy. The prediction model was implemented for the variables identified as dependent and independent, and finally, its performance was evaluated using the metrics of Mean Absolute Error (MAE), Mean Squared Error (MSE), and Root Mean Squared Error (RMSE). The results indicate that the model is capable of predicting fuel consumption, with low errors in quantitative values.

Key Words: Artificial intelligence; evaluation metrics; feature engineering; fuel forecasting; machine learning; random forest.

Resumo: Na indústria aeronáutica, os custos de produção do hidrocarboneto JET A-1 experimentam um aumento de aproximadamente 5% semanalmente ao longo dos anos, o que resultou em um aumento nos gastos para os operadores aéreos. Esta pesquisa propõe criar um modelo de previsão de consumo de combustível para voos regionais, com base em dados coletados de voos de uma companhia aérea colombiana durante o período de 2018-2019. Para criar o modelo preditivo, foi utilizada a biblioteca Sci-Kit Learn da linguagem de programação Python, e o problema foi abordado a partir de uma perspectiva de ‘problema inverso’. Em seguida, foi realizada a engenharia de características para melhorar a qualidade do conjunto de dados obtido e permitir uma maior precisão na previsão. O modelo de previsão foi implementado para as variáveis identificadas como dependentes e independentes e, finalmente, seu desempenho foi avaliado usando as métricas de Erro Absoluto Médio (MAE), Erro Quadrático Médio (MSE) e Raiz do Erro Quadrático Médio (RMSE). Os resultados indicam que o modelo é capaz de prever o consumo de combustível, com baixos erros em valores quantitativos.

Palavras-chave: Aprendizado de máquina; engenharia de recursos; floresta aleatória; inteligência artificial; métricas de avaliação; previsão de combustível.

Introducción

La demanda de pasajeros en Colombia ha tenido un crecimiento aproximado de 5 % año tras año entre 2011 y 2019 (Girón-Girón, 2023). Ahora bien, la pandemia de la COVID-19 tuvo gran repercusión a nivel global y derivó en una caída porcentual del 73 % en demanda de pasajeros; sin embargo, a partir de la reactivación de la economía la demanda de pasajeros ha tenido un crecimiento anual de alrededor del 4 % (Viñas y Gómez, 2023). Este crecimiento es importante analizarlo en los planes o estrategias a futuro de los operadores aeronáuticos colombianos y mundiales, con el propósito de pronosticar los costos de operación y la rentabilidad a corto, mediano y largo plazo.

Los aviones a reacción modernos en la aviación comercial mundial utilizan el hidrocarburo del queroseno, también llamado JET A-1 (Orellano-Lasprilla, 2023). Este combustible ha presentado un aumento considerable, de casi 250 %, en periodos de cuatro años a nivel mundial (Morrison *et al.*, 2010), comportamiento que se logra evidenciar en la Figura 1 con una

adicional al costo final por tiquete para el usuario final, los operadores aeronáuticos deben velar por el uso óptimo del producto químico y evitar vuelos vacíos que representen pérdidas monetarias.

En pro de analizar el crecimiento de la actividad aérea en el territorio nacional, es importante tener en cuenta los gastos directos que esta conlleva. El consumo de combustible JET A-1 es un objeto de estudio que ha presentado avances desde la gestión administrativa hasta usos de algoritmos de inteligencia artificial. Ahora bien, sabiendo que el uso del hidrocarburo representa en la actividad económica de las empresas aéreas un valor representativo entre el intervalo del 22 al 38 % de los gastos de la actividad aérea (Rativa-Sáenz, 2022), buscar la optimización en el uso del recurso es eje primordial para una rentabilidad futura.

Algunos estudios académicos se han realizado para predecir el consumo de combustible, acogiendo métodos de *big data*¹, inteligencia artificial, redes neuronales, modelos de optimización de trayectoria de vuelo, etc. En el avance de uso de estas tecnologías, se ha utilizado el pronóstico de consumo de combustible en un entorno no aeronáutico mediante




Figura 1. Histórico de precios de combustible JET A-1

Fuente: International Air Transport Association [IATA], 5 de abril de 2024.

tendencia al alza del crudo y combustible JET A-1 que permanece desde mayo de 2020. A raíz de esta problemática, que representa un porcentaje considerable

¹ Concerniente a bases de datos muy grandes, cuyo procesamiento incluye algoritmos complejos de procesamiento y es utilizado con frecuencia para alimentar proyectos de inteligencia artificial y redes neuronales (Sardi *et al.*, 2020).

las tendencias de Google con base en *big data*, con el fin de generar una relación entre las exploraciones de ‘consumo de combustible’ en la herramienta de búsqueda y el consumo real de combustible (Yu *et al.*, 2019). Estos avances permiten buscar diferentes soluciones para generar una predicción eficaz del consumo de combustible general.

Adicional a lo anterior, se han desarrollado estudios para la gestión eficiente del consumo de combustible en vuelos de aeronaves mediante la creación de un modelo de optimización en la trayectoria que tiene en cuenta variables físicas como coeficiente de arrastre, velocidad de crucero, etc., lo cual permitió establecer un modelo de rendimiento de aeronave según simulaciones de manejo de tráfico aéreo, impactos ambientales, etc. (Mouillet *et al.*, 2018). El enfoque se aproxima a una predicción real del consumo de combustible mediante la creación de trayectorias de vuelo, a razón de la utilización de otros factores importantes que toman lugar cuando se realiza un vuelo en las aeronaves. Sin embargo, esta aproximación tuvo como objetivo el cálculo de rutas aéreas mas no la optimización del consumo de combustible, lo cual afecta su uso en el desarrollo del objetivo principal.

Por último, la optimización del consumo de combustible en transporte aéreo ha sido un tema recurrente desde 1973; cerca de doscientos artículos abordan el tema con propuestas de soluciones siguiendo una metodología analítica, conceptual y matemática, hasta el moldeo de simulaciones, la programación dinámica y la programación lineal (Singh & Sharma, 2015). Por tal razón, este artículo tiene el objetivo de generar una innovación al hacer uso de nuevos algoritmos de predicción, buscando formas de optimizar el consumo de combustible JET A-1.

Aprendizaje automático (*machine learning*)

La gestión eficiente del consumo de combustible fue categorizada como un *inverse problem*, concepto que según Gallet *et al.* (2022) se refiere a la fórmula que relaciona el sistema y los datos de un ambiente específico. En el caso del pronóstico de consumo de combustible, se ha esquematizado el montaje que se

puede evidenciar en la Figura 2, en la que existen tres escenarios: el sistema, que representa el consumo del carburante; los datos, que son las variables obtenidas a través de la recopilación cíclica de antecedentes de vuelos en un determinado periodo de tiempo; y el método, que actúa como puente entre los datos y el sistema a focalizar, consistente en un algoritmo de predicción que se denominó como *inverse problem* o inteligencia artificial desarrollada.

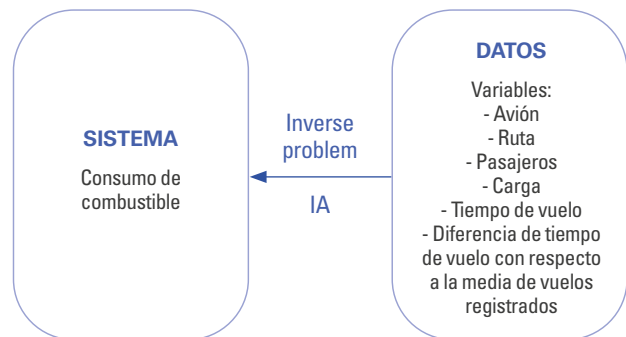


Figura 2. Esquema de problema inverso
Fuente: elaboración propia.

Gracias a la idealización del concepto del *inverse problem* es que existen muchas de las teorías físicas que rigen nuestro día a día. El caso de la representación de la fórmula de la atracción gravitacional entre dos masas existe a razón de que se tenía un sistema, la tierra y su satélite natural, y unos datos como la masa y la distancia. Se logró describir este comportamiento por medio de una fórmula y así explicar la atracción gravitacional de los cuerpos celestes (Pizlo, 2001). La inteligencia artificial generada es la fórmula que explica la relación entre los datos y el consumo de combustible de la aeronave objeto de estudio de la aerolínea.

El manejo de los datos independientes como el avión, la ruta, el número de pasajeros, la cantidad de carga, el tiempo de vuelo y la diferencia del tiempo de vuelo en relación con la media fue realizado a través del concepto de ingeniería de características, conocido en inglés como *feature engineering*. La ingeniería de características es una serie de características que enfocan sus esfuerzos en mejorar la calidad de los datos que se usen como *dataset* en un modelo de *machine learning*. Estas técnicas conceptualizan desde el

ingreso de datos faltantes a la base de datos, hasta el escalamiento de los datos con el objetivo de ajustarlos a una misma escala y que exista una mejor correlación (Panda *et al.*, 2021).

La inteligencia artificial es un campo integrado en las ciencias computacionales, cuya finalidad es plantear modelos de predicción con un esquema paralelo a las neuronas biológicas del ser humano, mediante una serie de redes neuronales donde ingresa información, tiene sus propios pesos y genera un resultado. En la Figura 3, se puede observar la esquematización de una red neuronal en la analogía conceptual científica con una neurona biológica humana. La analogía representa las entradas de información como valores específicos, así como en una neurona biológica los pulsos eléctricos llevan información del sistema nervioso; luego se da la sinapsis, donde se encuentran los diferentes pesos que permitirán la distorsión necesaria de la información proporcionada por las dendritas; después se identifica el cuerpo celular, donde reside el umbral que permite la sumatoria de información y/o funciones de activación necesarias para procesar la información, y en una neurona biológica el núcleo procesa la información y genera un resultado; por último, se expide la información a través del axón, siendo el resultado esperado de la red neuronal un valor numérico.




Figura 3. Esquematización de una red neuronal
Fuente: elaboración propia.

La inteligencia artificial permite la generación de modelos de predicción y autoaprendizaje en diferentes escenarios, desde la visión computarizada hasta el reconocimiento de voz. A su vez, existen diferentes tipos de aprendizaje dentro de la computación predictiva, cada uno con ventajas y desventajas que dan paso

a una variedad de modelos de aprendizaje automatizado para cada escenario (Márquez-Díaz, 2020).

En el estudio de las tecnologías con inteligencia artificial, el aprendizaje automático (o en inglés *machine learning*) juega un papel fundamental: es un proceso que se ha utilizado para generar el modelo de predicción, por cuanto su principal función es el aprendizaje de las computadoras mediante el entrenamiento de algoritmos con datos especificados en su época de entrenamiento, con el fin de realizar tareas de clasificación, generación o conceptualización de nuevos datos (Janiesch *et al.*, 2021). La selección del aprendizaje automático genera una gran ventaja cuando se deben realizar tareas repetitivas cuyos datos caractericen una relación al resultado deseable.

Para profundizar en las diferentes secciones de *machine learning*, el aprendizaje supervisado (o en inglés *supervised learning*) es un modelo de predicción entrenado con datos etiquetados con anterioridad, que tiene el objetivo de generar un modelo de IA capaz de clasificar o producir datos con etiquetas usadas en una escala física; el algoritmo es usado para análisis de texto (NLP), visión computacional o generación de datos a partir de la relación entre ellos (Baevski *et al.*, 2022). Debido a la capacidad de generación de datos del aprendizaje supervisado, fue posible generar el pronóstico de consumo de combustible mediante un algoritmo especializado para los datos que se habían obtenido.

La idealización de un modelo de predicción implica, de igual manera, seleccionar la clasificación correcta de aprendizaje automático supervisado. *Random forest* fue el algoritmo adecuado para la generación de los datos dependientes o la cantidad de combustible para efectos prácticos. El algoritmo tiene la misión de generar árboles de decisión sobre un conjunto de datos de entrenamiento, los cuales trabajan con un subconjunto aleatorio de variables y cada árbol llega hasta su máxima extensión. Luego de obtener un resultado por cada árbol, se realiza un proceso de *soft voting*² si

² Algoritmo que es utilizado para combinar pronósticos de varios clasificadores o árboles mediante la probabilidad de estas (Fieri y Suhartono, 2023).

la variable es categórica, o de promedio si es numérica, lo que permite una precisión elevada en comparación con otros modelos de predicción similares (Espinoza-Zúñiga, 2020). En la Figura 4, se puede visualizar de manera gráfica el proceso de un algoritmo de *random forest* para la generación o clasificación de datos.

se observan las secciones de los diferentes algoritmos que componen el objetivo del presente artículo.

La evaluación de un modelo de predicción se realiza mediante métricas estadísticas, las más conocidas son MAE, MSE y RMSE³. La primera, el MAE, toma la diferencia entre el resultado esperado y el resultado

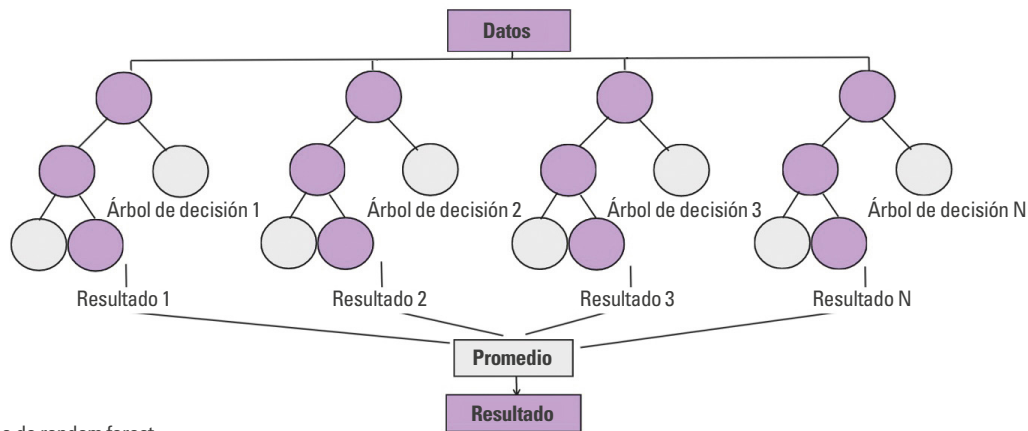


Figura 4. Esquema de random forest

Fuente: elaboración propia.

Dentro de la solución planteada para la aplicación de un modelo predictivo de consumo de combustible, es crucial conocer la clasificación idónea para el uso del algoritmo de *random forest*. La inteligencia artificial engloba diferentes metodologías y *machine learning* es el concepto más utilizado para la creación de procedimientos de automatización, pues dentro de este se encuentran las metodologías de aprendizaje supervisado, las cuales se conforman por métodos en que los datos para entrenamiento ya están etiquetados, sabiendo su unidad de medida y alcance. Finalmente, tenemos al *random forest*, algoritmo seleccionado para la resolución de la problemática planteada (Duarte y Berton, 2023). En la Figura 5,

obtenido, realiza una sumatoria y la divide entre el número total de cantidad de la muestra; el resultado se presenta en las unidades utilizadas y su ventaja radica en la facilidad del análisis. Las otras dos, el MSE y la RMSE, son similares. La primera corresponde a la diferencia cuadrática de los valores esperados y obtenidos, haciendo sumatoria de estas sustracciones y la división con el total de unidades de la muestra; mientras que la segunda toma el valor del MSE y realiza el proceso de radicación. Las ventajas de utilizar estas dos métricas radican en la penalización de los errores más grandes. Sin embargo, el MSE no utiliza las unidades esperadas, es razón primordial que la RMSE sea más utilizada que el anterior (Hodson, 2022). En todas las métricas expuestas, se busca que el resultado sea lo más cercano a 0, lo que indicaría que la diferencia entre los resultados esperados y obtenidos es nula y que el modelo de predicción es perfecto. En la Tabla 1, se observa la comparación entre las tres métricas utilizadas.




Figura 5. Esquema de IA a random forest

Fuente: elaboración propia.

³ Respectivamente: error absoluto medio, error cuadrático medio y raíz del error cuadrático medio, por sus siglas en inglés.

Tabla 1.
Métricas de modelo de predicción

Métrica	Fórmula	Unidades	Ventaja	Desventaja
MAE	$\frac{1}{n} \sum_{i=1}^n y_1 - \hat{y}_i $	Las mismas de los datos.	Mejor comprensión, uso comercial.	No penaliza errores grandes.
MSE	$\frac{1}{n} \sum_{i=1}^n (y_1 - \hat{y}_i)^2$	Las mismas de los datos al cuadrado.	Penalización de errores grandes.	No maneja las mismas unidades que los datos.
RMSE	$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_1 - \hat{y}_i)^2}$	Las mismas de los datos.	Penalización de errores grandes, unidades iguales que los datos.	Posible sesgo a errores grandes poco frecuentes.

Fuente: elaboración propia.

Método

La metodología propuesta en este estudio se fundamenta en el enfoque CRISP-MD, estructurado en cuatro etapas principales, tal como se ilustra en la Figura 6. Este enfoque sistemático comienza con un análisis exploratorio de datos, donde se examina detenidamente el conjunto de datos para comprender sus características y patrones subyacentes. A continuación, se procede a la identificación de las características clave de los datos, lo que permite una mejor comprensión de las

variables significativas que contribuyen al fenómeno en estudio. La tercera etapa consiste en la creación del modelo, donde se emplean técnicas de aprendizaje automático o estadísticas para desarrollar una representación matemática del fenómeno. Finalmente, se realiza una evaluación exhaustiva del modelo, aplicando métricas y pruebas relevantes para determinar su precisión, robustez y aplicabilidad en contextos específicos. Esta metodología integral garantiza un enfoque sistemático y riguroso para el análisis de datos, alineado con los estándares científicos actuales (Schröer *et al.*, 2021).

Aplicación de la imputación simple

Durante la fase de análisis exploratorio de datos (AED), se identificó una deficiencia en el conjunto de datos, particularmente en relación con la falta de información en ciertas variables críticas. Esta carencia requirió la implementación del primer procedimiento de ingeniería de características, utilizando una clase específica del módulo Sci-Kit Learn en Python. Dicha clase ofrece varias estrategias para imputar los valores ausentes, como la media, la mediana, la moda o una constante predefinida. Tras un cuidadoso examen y evaluación de estas metodologías, se determinó que la imputación mediante la media era la más congruente con la naturaleza de los datos en cuestión. Por lo tanto, esta estrategia se aplicó a todas las columnas relevantes en las que se había detectado la omisión de

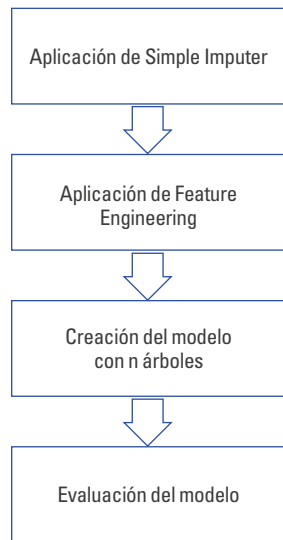


Figura 6. Flujograma de creación del modelo
Fuente: elaboración propia.

información, con el objetivo de prevenir cualquier posible sesgo en futuras interpretaciones o análisis, en caso de que el modelo asumiera de manera predeterminada un valor nulo o cero para los datos faltantes.

Ingeniería de características

A raíz de obtener los datos adecuados, era necesario realizar un ajuste a sus escalas dado que se trataban de diferentes variables. En el lenguaje de programación Python, existen varias herramientas para realizar el escalamiento: *standard*, *min-max scaled*, *quantile scaled*, *max-abs scaled*, *power scaled* y *robust scaled*. Todas estas provienen del módulo Sci-Kit Learn en su sección de *preprocessing*. En la Figura 7, se puede evidenciar de manera gráfica el cambio de escala de los datos utilizados, incluyendo su escala original. El objetivo de la realización de los escalamientos es disminuir la diferencia de unidades de medida entre las variables estudiadas y evitar la consecuencia de posibles sesgos de este escenario.

Se observan diferentes comportamientos de las variables en distintos escenarios, donde las variables ‘Carga’, ‘PAX’, ‘Diferencia’ y ‘Tvuelo_min’ cambian su escala debido a la característica aplicada. Las variables utilizadas corresponden a las cantidades pertinentes por vuelo en una aeronave específica, a saber: la primera variable se refiere a la cantidad de carga aérea en kilogramos; ‘PAX’ es la abreviación de cantidad de pasajeros; ‘Diferencia’ radica en el procedimiento aritmético de resta entre el promedio de duración del vuelo y la duración estimada en minutos; por último, ‘Tvuelo_min’ conceptualiza la duración estimada del vuelo en minutos.

Creación del modelo

La implementación del algoritmo de *random forest* para nuestros datos se realizó a través de la clase Random Forest Regressor; sin embargo, fue necesario dividir los datos obtenidos en dos: datos de entrenamiento y datos de prueba. Los datos de entrenamiento

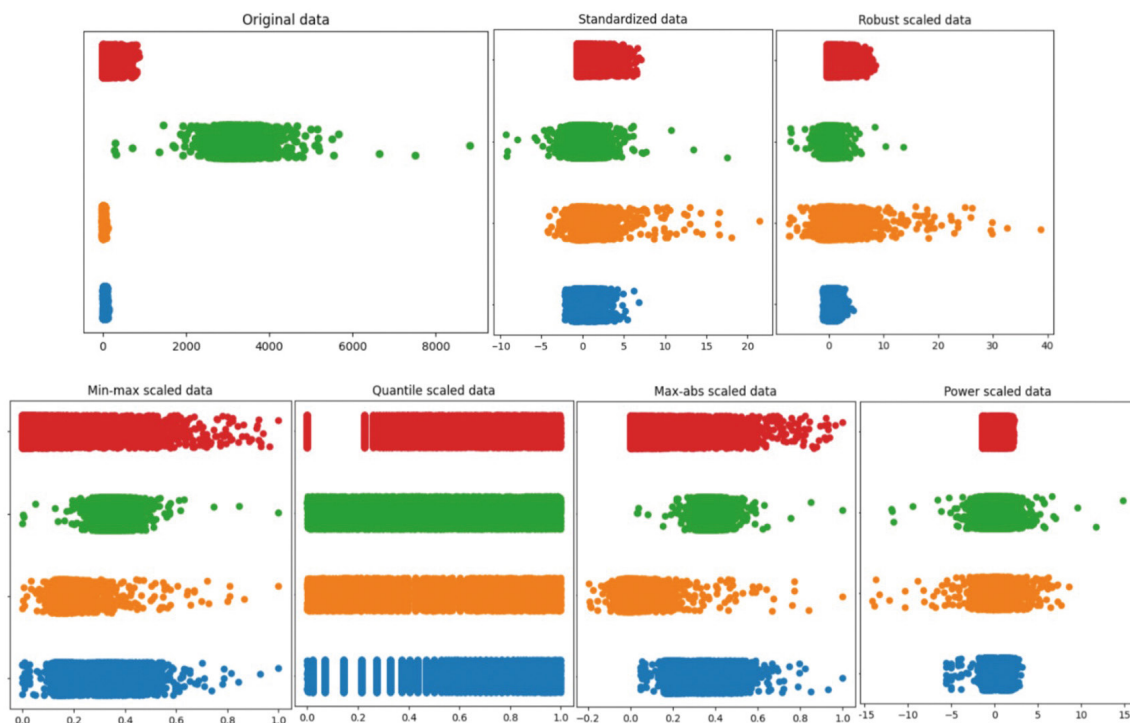


Figura 7. Características aplicadas al conjunto de datos

Fuente: elaboración propia.

usualmente representan el 80 % del total de los datos disponibles y ayudarán a entrenar el modelo de predicción; por su parte, los datos de prueba son el porcentual restante, en este caso el 20 %, y con estos se realizarán las pruebas con las métricas de MAE, MSE y RMSE, y se evidencia la calidad del modelo. Esta división se realiza con el fin de evitar el *overfitting*.

El *overfitting* es un problema que se puede encontrar al entrenar modelos de predicción supervisados, y tiene lugar cuando el modelo memoriza los datos de entrada y su relación con el resultado esperado, pero no aprende a relacionarlos, lo cual ocasiona un caos cuando se enfrenta a nuevos datos que no estaban en el *dataset* de entrenamiento (Ying, 2019). Un ejemplo de este suceso se evidencia cuando un estudiante de primaria se encuentra en el proceso de aprendizaje de los productos básicos; sin embargo, por diversos factores, no aprende el proceso detrás del producto, que es la abreviación de la adición, sino que memoriza los productos y sus múltiplos, por lo cual cuando se enfrenta a nuevos múltiplos o en un diferente orden no será capaz de responder correctamente.

Para evitar este inconveniente, se hace uso de la clase *train_test_split*, lo que permitirá la división necesaria de los datos. Se hace uso de esta clase para separar los datos y también se da la utilización de la clase de Random Forest Regressor con una cantidad de árboles de decisión indicada por la variable de *n_estimators*, siendo una cantidad utilizada de 500. Se obtiene el modelo para su ajuste con la opción *fit* y se hace uso de él con las variables independientes de prueba para generar unos valores dependientes con el modelo desarrollado gracias a la función *.predict*.

Evaluación modelo

Finalmente, tras la obtención de las variables dependientes utilizando el modelo generado, se llevó a cabo una evaluación meticulosa de la predicción mediante la implementación de métricas específicas, como el MAE, el MSE y la RMSE. Para llevar a cabo esta evaluación, se importó la clase *metrics* del módulo Sci-Kit Learn. El proceso de aplicación de estas funciones de evaluación, que toman como entrada los valores de

prueba y los valores pronosticados por el modelo, se da por medio de las funciones *mean_absolute_error*, *mean_squared_error* y la raíz de la anterior función para sus homólogos MAE, MSE y RMSE, respectivamente.

Resultados

El modelo predictivo desarrollado utilizando la biblioteca Sci-Kit Learn y la técnica de *random forest* ha demostrado una capacidad adecuada para predecir el consumo de combustible, con errores bajos reflejados en las métricas de MAE, MSE y RMSE. A través de la ingeniería de características y la inclusión de variables como tiempo de vuelo, carga, cantidad de pasajeros y promedio de tiempo de vuelo, se observó una variabilidad significativa en el consumo de combustible. Los resultados destacaron que los incrementos en la carga, los pasajeros y las variaciones en el tiempo de vuelo condujeron a una predicción del consumo de combustible.

Tras llevar a cabo el entrenamiento del algoritmo de aprendizaje supervisado destinado a la predicción del consumo de combustible para vuelos regionales en una aerolínea colombiana, se procedió a una evaluación meticulosa del desempeño del modelo en cada enfoque de ingeniería de características implementado. La evaluación fue diseñada para medir la precisión y eficacia del modelo en la predicción de variables complejas, reflejando así la aplicabilidad de diferentes técnicas de ingeniería de características. Una comparación detallada entre los enfoques se presenta en la Tabla 2, y permite un análisis riguroso y profundo de cómo cada método contribuyó al rendimiento global del modelo. Este análisis comparativo es vital para identificar las técnicas más prometedoras y para orientar futuras investigaciones y desarrollos en la predicción eficiente del consumo de combustible en el contexto de la aviación regional en Colombia.

La tabla presentada ilustra la aplicación de seis técnicas de escalado: *standard scaled*, *min-max scaled*, *quantile scaled*, *max-abs scaled*, *power scaled* y *robust scaled*, las cuales fueron implementadas como parte

del proceso de ingeniería de características en los datos de entrenamiento utilizados en el algoritmo de aprendizaje automático desarrollado. La efectividad de cada técnica se evaluó con rigurosidad mediante tres métricas estandarizadas comúnmente utilizadas en la valoración de algoritmos de pronóstico cuantitativos: el MAE, el MSE y la RMSE. Estas métricas ofrecen una valoración cuantitativa y objetiva de la precisión de los valores pronosticados por el modelo.

Tabla 2.
Métricas finales

Feature	MAE (kilogramos de combustible)	MSE (kilogramos cuadrados de combustible)	RMSE (kilogramos de combustible)
<i>Standard scaled</i>	23,9867	1319,0599	36,3188
<i>Min-max scaled</i>	23,5430	1286,4400	35,8669
<i>Quantile scaled</i>	23,5402	1286,1340	35,8627
<i>Max-abs scaled</i>	23,5425	1286,3764	35,8660
<i>Power scaled</i>	23,5420	1288,4789	35,8953
<i>Robust scaled</i>	23,5037	1285,0845	35,8480

Fuente: elaboración propia.

Entre las técnicas evaluadas el método *robust scaled* se distinguió por su rendimiento superior, prevaleciendo sobre otras técnicas en todas las métricas cuantitativas analizadas. Con un MAE de 23,5037, un MSE de 1285,0845 y una RMSE de 35,8480, este enfoque demostró una capacidad destacada para generar predicciones precisas del consumo de combustible. Tales predicciones reflejan con gran aproximación el consumo real de combustible en vuelos regionales de una aerolínea comercial colombiana, y evidencian la efectividad del modelo en contextos operativos reales.

Los valores derivados de estas métricas indican que el modelo empleando la técnica de *robust scaled* exhibe un error promedio aproximado de 23 kg de combustible y alcanza un máximo de 36 kg en el escenario menos favorable. Estos hallazgos son prometedores, ya que evidencian un progreso notable en la implementación de inteligencia artificial para la predicción precisa del consumo de combustible dentro del sector aeronáutico colombiano. Además, la adopción de este

modelo podría conducir a una gestión más eficiente del combustible, resultando en una reducción significativa de los costos operativos habituales. Finalmente, los resultados no solo representan un avance tecnológico para la industria aeronáutica, sino que también fomentan la sostenibilidad y la eficiencia económica en Colombia.

Discusión

En la creación del diseño de un algoritmo de inteligencia artificial para el pronóstico de consumo de combustible, se observó que además de las variables consideradas para el estudio y entrenamiento de la red neuronal, se debieron considerar más factores indispensables que tienen gran relevancia durante el vuelo de cualquier aeronave comercial en Colombia.

- **Condiciones meteorológicas:** La variabilidad en las condiciones meteorológicas afecta significativamente el consumo de combustible al alterar las rutas de vuelo y los tiempos de vuelo. El modelo mostró sensibilidad a estas variaciones dado que no se tuvo ningún estado de clima afectando las métricas de evaluación; sin embargo, la integración de datos meteorológicos más detallados y en tiempo real podría mejorar la robustez del modelo (Cheung *et al.*, 2023).
- **Tráfico aéreo:** Las condiciones de tráfico aéreo, incluyendo la congestión y las rutas alternativas, tienen un impacto significativo en el consumo de combustible. Durante periodos de alta congestión, los aviones pueden requerir rutas más largas o tiempos de espera en vuelo, lo cual inevitablemente aumenta el consumo de combustible. Este factor puede introducir variaciones en el modelo que no fueron completamente anticipadas en las fases iniciales de desarrollo (Rosenow *et al.*, 2019). Aumentar la integración de datos en tiempo real sobre condiciones de tráfico podría mejorar la adaptabilidad y la precisión del modelo.

- **Mantenimiento de los motores:** El estado de mantenimiento de los motores de la aeronave juega un papel crucial en el rendimiento del consumo de combustible. Motores bien mantenidos operan de manera más eficiente, consumiendo menos combustible y reduciendo las emisiones (Hassan *et al.*, 2021). Un modelo que incluya variables relacionadas con el historial de mantenimiento y la salud actual de los motores podría ofrecer predicciones más precisas, pues reflejaría el impacto directo del mantenimiento en el consumo de combustible.

Todos estos factores deben ser considerados en futuras mejoras del modelo para aumentar su precisión y aplicabilidad en condiciones operativas variables. En relación con los resultados obtenidos a través de las métricas de los diferentes *features*, se puede denotar que hay un mejor rendimiento en el *robust scaled*. El escalamiento de los datos que se presentan en este enfoque se produce al eliminar la media y la escala de los datos según los rangos de los cuantiles de manera predeterminada. El rango es entre el primer cuartil (o mediana de la primera mitad de los valores) y el tercer cuartil (o mediana de la segunda mitad de los valores), con lo que representan el vigésimo quinto cuartil y el septuagésimo quinto cuartil (Pedregosa *et al.*, 2011). El escalamiento permite evadir el sesgo que se presenta con valores extremos de los datos, lo cual ocurre al eliminar la media (o promedio) y permite que el valor de los datos cercanos a la distribución tenga un mayor impacto.

La aplicación del enfoque *robust scaled* en los datos de entrenamiento para el modelo de predicción del consumo de combustible resultó en una mejora apreciable, con un aumento cercano al 0,4994 % en las métricas de evaluación en comparación con otros métodos empleados. Es relevante destacar que este escalamiento o enfoque aplicado a los datos contribuyó a atenuar el sesgo y, por lo tanto, a neutralizar los efectos adversos que los valores atípicos pudieran tener en modelos de predicción fundamentados en datos de entrenamiento.

Por otro lado, los datos obtenidos de las métricas presentan una desviación considerable, evidenciando

un desajuste aproximado del 25 % en relación con los datos reales. Este desarreglo podría ser indicativo de la influencia de los factores mencionados antes. Para optimizar el modelo de predicción, se requiere un análisis detallado y riguroso que abarque desde la inclusión de datos faltantes hasta la evaluación de la cantidad de árboles de decisión utilizados en el modelo, y también la consideración de la cantidad de datos de entrenamiento disponibles, además de buscar un conjunto de datos que pueda tener en cuenta.

Conclusiones

La implementación de algoritmos de *machine learning* para predecir el consumo de combustible en vuelos regionales ha demostrado ser una herramienta eficaz en la mejora de la planificación estratégica de una aerolínea colombiana, cumpliendo así el objetivo principal del estudio. Esta tecnología ha permitido a la aerolínea optimizar la gestión de su inventario de combustible, lo cual se traduce en decisiones más informadas sobre compras y almacenamiento. Al prever con precisión el consumo necesario por vuelo, la empresa ha logrado evitar tanto la escasez como el exceso en sus reservas, optimizando recursos y mejorando las utilidades.

Adicional a lo anterior, la aplicación de estos modelos predictivos ha contribuido a una reducción significativa de los costos operativos. La optimización en la planificación de vuelos ha minimizado los trayectos vacíos o subutilizados, maximizando así la eficiencia operativa y reduciendo gastos superfluos, lo cual se alinea directamente con el objetivo de mejorar la rentabilidad a través de tecnologías avanzadas.

Finalmente, la adopción de algoritmos de *machine learning* ha fomentado la colaboración entre la industria aeronáutica, el gobierno y la academia en Colombia, fortaleciendo el ecosistema tecnológico y promoviendo la innovación y el desarrollo de capacidades locales. Este enfoque colaborativo y de innovación tecnológica ha tenido un impacto positivo en la economía nacional y en la creación de oportunidades laborales en el sector tecnológico.

Referencias

- Baevski, A., Hsu, W.-N., Xu, Q., Babu, A., Gu, J. y Auli, M. (2022). data2vec: A General Framework for Self-Supervised Learning in Speech, Vision and Language. *Proceedings of Machine Learning Research*, 162, 1298-1312. <https://proceedings.mlr.press/v162/baevski22a.html>
- Cándaño-Viñas, L. y Gómez, M. (2023). El impacto de la covid-19 en la demanda turística internacional. *ININEE CIENCIA: Revista de Investigación Científica*, 1(1), 23-38. <https://doi.org/10.33110/inineeciencia.v1i1.5>
- Cheung, J. C. H., Wells, C. A. y Steele, E. C. C. (2023). Evaluation of Methods of Estimating Time-Optimal Flight Routes in a Changing Climate. *Meteorological Applications*, 30(2). <https://doi.org/10.1002/met.2121>
- Duarte, J. M. y Berton, L. (2023). A Review of Semi-Supervised Learning for Text Classification. *Artificial Intelligence Review*, 56(9), 9401-9469. <https://doi.org/10.1007/s10462-023-10393-8>
- Espinosa-Zúñiga, J. J. (2020). Aplicación de algoritmos Random Forest y xgBoost en una base de solicitudes de tarjetas de crédito. *Ingeniería, Investigación y Tecnología*, 21(3), 1-16. <https://doi.org/10.22201/fi.25940732e.2020.21.3.022>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. y Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12(85), 2825-2830. <https://tinyurl.com/5r9a3xxy>
- Fieri, B. y Suhartono, D. (2023). Offensive Language Detection Using Soft Voting Ensemble Model. *MENDEL: Soft Computing Journal*, 29(1), 1-6. <https://doi.org/10.13164/mendel.2023.1.001>
- Gallet, A., Rigby, S., Tallman, T. N., Kong, X., Hajirasouliha, I., Liew, A., Liu, D., Chen, L., Hauptmann, A. y Smyl, D. (2022). Structural Engineering from an Inverse Problems Perspective. *Proceedings of the Royal Society*, 478(2257). <http://doi.org/10.1098/rspa.2021.0526>
- Girón-Girón, L. Á (2023). Estimación de demanda de transporte aéreo de pasajeros desde un enfoque de redes para aeropuertos tipo hub: caso Aeropuerto El Dorado Bogotá (tesis de maestría, Universidad Nacional de Colombia). Repositorio institucional UNAL. <https://tinyurl.com/56beb5c6>
- Hassan, T. H., Sobaih, A. E. E. y Salem, A. E. (2021). Factors Affecting the Rate of Fuel Consumption in Aircrafts. *Sustainability*, 13(14). <https://doi.org/10.3390/su13148066>
- Hodson, T. O. (2022). Error cuadrático medio (RMSE) o error absoluto medio (MAE): cuándo usarlos o no. *Geoscientific Model Development*, 15(14), 5481-5487. <https://doi.org/10.5194/gmd-15-5481-2022>
- International Air Transport Association (IATA). (2024, abril 5). *Jet Fuel Price Monitor* [en línea]. <https://tinyurl.com/n27pdcaz>
- Janiesch, C., Zschech, P. y Heinrich, K (2021). Machine Learning and Deep Learning. *Electron Markets*, 31, 685-695. <https://doi.org/10.1007/s12525-021-00475-2>
- Lozano, C., Melo, P., Bermúdez, J., González, S. y Fuentes, S. (2023). Integración de algoritmos de inteligencia artificial en función del pronóstico de consumo de combustible en aeronaves ERJ 145 de una aerolínea colombiana [ponencia]. VII Congreso Argentino de Ingeniería Aeronáutica (CAIA 7), La Plata, Argentina, 29 de noviembre al 1 de diciembre de 2023. <https://tinyurl.com/2sr8kmp6>
- Márquez Díaz, J. (2020). Inteligencia artificial y Big Data como soluciones frente a la covid-19. *Revista de Bioética y Derecho*, (50), 315-331. <https://tinyurl.com/mr3mvac5>
- Morrison, J. K. D., Bonnefoy, P. A. y Hansman, R. J. (2010). *Investigation of the Impacts of Effective Fuel Cost Increase on the US Air Transportation Network and Fleet* [ponencia]. 10th AIAA Aviation Technology, Integration, and Operations Conference, 13-15 de septiembre de 2010. <https://tinyurl.com/vyjhrd9y>
- Mouillet, V., Nuic, A., Casado, E. y López-Leonés, J. L. (2018). Evaluación de la aplicabilidad de un modelo moderno de rendimiento de aeronaves para la optimización de trayectorias. IEEE/AIAA 37th Digital Avionics Systems Conference (DASC), 23-27 de septiembre de 2018. <https://doi.org/10.1109/dasc.2018.8569732>
- Orellano-Lasprilla, J. L. (2023). *Análisis fluido dinámico computacional de un mezclador estático para combustible de aviación JET A-1 y biodiesel* (tesis de maestría, Universidad ECCI). Repositorio institucional ECCI. <https://doi.org/10.1109/DASC.2018.8569732>
- Panda, M., Mousa, A. A., & Hassanien, A. E. (2021). Developing an efficient feature engineering and machine learning model for detecting IOT-botnet cyber attacks. *IEEE Access*, 9, 91038-91052. <https://doi.org/10.1109/access.2021.3092054>

- Pizlo, Z. (2001). Perception Viewed as an Inverse Problem. *Vision Research*, 41(24), 3145-3161. [https://doi.org/10.1016/S0042-6989\(01\)00173-0](https://doi.org/10.1016/S0042-6989(01)00173-0)
- Rativa-Sáenz, E. A. (2022). Análisis de series de tiempo para la estimación del consumo combustible en aeronaves ATR42 para aerolínea colombiana (tesis de especialización, Fundación Universitaria Los Libertadores). <https://tinyurl.com/3eaay68a>
- Rosenow, J., Fricke, H., Luchkova, T. y Schultz, M. (2019). Impact of Optimised Trajectories on Air Traffic Flow Management. *The Aeronautical Journal*, 123(1260), 157-173. <https://doi.org/10.1017/aer.2018.155>
- Sardi, A., Sorano, E., Cantino, V. y Garengo, P. (2020). Big Data and Performance Measurement Research: Trends, Evolution and Future Opportunities. *Measuring Business Excellence*, 27(4), 531-548. <https://doi.org/10.1108/mbe-06-2019-0053>
- Schröer, C., Kruse, F. y Gómez, J. M. (2021). A Systematic Literature Review on Applying CRISP-DM Process Model. *Procedia Computer Science*, 181, 526-534. <https://doi.org/10.1016/J.PROCS.2021.01.199>
- Singh, V., & Sharma, S. K. (2015). Fuel consumption optimization in air transport: A review, classification, critique, simple meta-analysis, and future research implications. *European Transport Research Review*, 7(2). <https://doi.org/10.1007/s12544-015-0160-x>
- Ying, X. (2019). An Overview of Overfitting and its Solutions. *Journal of Physics: Conference Series*, 1168. <https://doi.org/10.1088/1742-6596/1168/2/022022>
- Yu, L., Zhao, Y., Tang, L. y Yang, Z. (2019). Online Big Data-Driven Oil Consumption Forecasting with Google Trends. *International Journal of Forecasting*, 35(1), 213-223. <https://doi.org/10.1016/j.ijforecast.2017.11.005>